

FALCON-1 PoC

기술 분석 보고서 (Tech Analysis Report)

영역 G — HRI · 음성 (8종)

[accent : ORANGE]

프로젝트 : FALCON-1 (Flow-Assisted Logistics & Collaborative Operation Network — One)

팀 : NERDLABS | 버전 : v0.1 | 작성일 : 2026-04-30

작성자 : 이건희 (NERDLABS 팀장) | 검토 : CTO 페르소나

보고서 BLUF

BLUF FALCON-1 HRI·음성 영역 8종 분석 결과: faster-whisper medium + Silero VAD + Piper TTS = MUST 3종 (한국어 음성 명령 핵심), Whisper-large v3 turbo + WhisperX = SHOULD (BRAVO 8GB GPU에서 95% 정확도 사수 시), Coqui XTTS v2 = SHOULD (자연스러운 한국어 응답, Sprint 5 narrative), OpenAI Whisper API + ESPnet = 비채택 (외부 의존·복잡성). v1.0은 PTT (Push-To-Talk) primary + VAD fallback 정책으로 ESP32 헬멧 수동 트리거 → faster-whisper medium 한국어 90-93% 정확도 → 의도 파싱 → Piper TTS 한국어 응답 (~200ms). BRAVO 8GB GPU 활용 시 Whisper-large turbo로 95%+ 정확도 사수 가능.

본 보고서는 영역 A(미들웨어 + ESP32 micro-ROS) + B(PTP) + E(MediaPipe Hands)을 전제로 한다. ESP32-S3 헬멧 wearable이 Wi-Fi 5GHz로 음성 stream을 RPi5 또는 L1으로 전송, ROS 2 토픽 /helmet/audio_in이 ASR 노드로 들어간다.

본 영역의 accent 색상은 ORANGE (소통·따뜻함 의미)을 사용한다.

영역 G — 8종 요약 매트릭스

#	기술	용도	한국어	처리 위치	권장도	적용
G1	faster-whisper medium	ASR (90-93%)	✓	L1 GPU 또는 RPi5	★★★★★	MUST
G2	Silero VAD	음성 활성화 (PTT fallback)	language-agnostic	RPi5 CPU	★★★★★	MUST
G3	Piper TTS	한국어 음성 응답 (~200ms)	✓ko-KR ONNX	RPi5 CPU	★★★★★	MUST
G4	Whisper-large v3 turbo	ASR 95%+	✓95%+	BRAVO GPU	★★★★★	SHOULD (Sprint 4)
G5	Coqui XTTS v2	자연스러운 TTS	✓다국어 (16 언어)	L1 GPU	★★★	SHOULD (Sprint 5)

#	기술	용도	한국어	처리 위치	권장도	적용
G6	OpenAI Whisper API	Cloud ASR	✔95%+	외부 cloud	★★	비채택 (외부 의존)
G7	WhisperX	ASR + word timestamp	✔	L1 GPU	★★★★	SHOULD (Sprint 4)
G8	ESPnet ko-KR	한국어 학술 ASR/TTS	✔	L1 GPU	★★	비채택 (학술용)

G1. faster-whisper (medium model)

BLUF ★★★★★ MUST 채택. OpenAI Whisper의 CTranslate2 최적화 구현, 4-5x 가속 + 메모리 효율. Medium 모델 (769M)이 한국어 90-93% 정확도, RTX 3060 6GB FP16에서 4x realtime, RPi5 ARM CPU에서 0.5x realtime (streaming 가능). FALCON-1 v1.0 ASR 표준 — PTT 트리거 시 1-3초 음성을 100-300ms 안에 텍스트 변환.

1. 개요

항목	내용
풀네임	faster-whisper (CTranslate2 backend)
라이선스	MIT
관리	Guillaume Klein (CTranslate2) + Whisper 커뮤니티
기반 모델	OpenAI Whisper (large-v3, medium, small 등)
가속 backend	CTranslate2 (CUDA + INT8 양자화)
속도 (medium)	RTX 3060 4x realtime, RPi5 0.5x realtime

항목	내용
언어	Python primary
VRAM (medium FP16)	약 2.5 GB
VRAM (medium INT8)	약 1.5 GB

2. 적용 방법

2.1 설치

```
# Python 설치
pip install faster-whisper

# CUDA 11.8 또는 12.x 사전 설치 필요
nvidia-smi # GPU 확인

# 한국어 전용 fine-tuned 모델은 별도 (default multilingual로 충분)
```

2.2 ROS 2 통합 노드 (FALCON-1)

```
# whisper_asr_node.py
import rclpy
from rclpy.node import Node
from std_msgs.msg import String, Bool
from audio_common_msgs.msg import AudioData
from faster_whisper import WhisperModel
import numpy as np

class WhisperNode(Node):
    def __init__(self):
        super().__init__('whisper_asr')
        # Medium FP16 on RTX 3060 - 4x realtime
        self.model = WhisperModel(
            'medium', device='cuda', compute_type='float16')
        # 또는 RPi5 fallback:
        # self.model = WhisperModel('small', device='cpu', compute_type='int8')

        self.audio_buf = []
        self.recording = False

        self.sub_ptt = self.create_subscription(
            Bool, '/helmet/ptt', self.cb_ptt, 10)
        self.sub_audio = self.create_subscription(
            AudioData, '/helmet/audio_in', self.cb_audio, 100)
        self.pub_text = self.create_publisher(
            String, '/asr/transcript', 10)
```

```
def cb_ptt(self, msg):
    if msg.data:
        self.recording = True
        self.audio_buf = []
    else:
        self.recording = False
        self.transcribe()

def cb_audio(self, msg):
    if self.recording:
        self.audio_buf.extend(msg.data)

def transcribe(self):
    audio = np.array(self.audio_buf, dtype=np.float32) / 32768.0
    segments, info = self.model.transcribe(
        audio,
        language='ko',      # 한국어 지정
        beam_size=5,
        vad_filter=True,    # 내장 VAD
    )
    text = ' '.join([s.text for s in segments]).strip()
    self.pub_text.publish(String(data=text))
    self.get_logger().info(f'[ASR] {text}')
```

2.3 모델 크기별 성능 (한국어, FALCON-1 측정 예상)

모델	파라미터	VRAM (FP16)	RTX 3060 속 도	RPi5 속도	한국어 WER	FALCON-1 권장
tiny	39 M	0.5 GB	20x realtime	5x realtime	20-30%	비권장
small	244 M	1.2 GB	8x realtime	1x realtime	10-15%	RPi5 fallback
medium	769 M	2.5 GB	4x realtime	0.5x realtime	7-10%	✔MUST primary
large-v3	1.55 B	5 GB	1.5x realtime	✗	5-8%	BRAVO 가능 (G4 turbo 권장)
large-v3 turbo	809 M	3.2 GB	3x realtime	✗	5-8%	BRAVO 권장 (G4)

3. 하드웨어 필요·제약

항목	최소	권장	FALCON-1 적합성
GPU	GTX 1650 4GB	RTX 3060+ 6GB	✔TUF (3060) primary
VRAM (medium)	2.5 GB FP16	—	✔TUF 6GB OK
CPU only fallback	ARM A76 4코어	x86 quad+	□ RPi5 small INT8 가능
RAM	4 GB	8 GB+	✔
CUDA	11.8 / 12.x	12.x	✔Ubuntu 24.04
입력 audio	16 kHz mono float32	—	✔ESP32 헬멧 표준

4. 장점

- 1. Whisper 의 4-5x 가속 — CTranslate2 INT8/FP16 최적화
- 2. MIT 라이선스 상용 친화
- 3. 99 언어 지원 — 한국어·영어 동시 detection 가능
- 4. 내장 VAD (Silero) — vad_filter=True 로 자동 음성 활성화
- 5. Word timestamp 옵션 — WhisperX(G7) 통합 가능
- 6. RTX 3060 medium — 4x realtime, latency 100-300ms
- 7. RPi5 small fallback — GPU 없을 때 1x realtime 가능
- 8. Beam search + temperature — 정확도 vs 속도 trade-off 조정

5. 단점·한계

- 9. CTranslate2 의존 — CUDA 호환성 issue 종종 (cuDNN version mismatch 등)
- 10. Streaming ASR 미지원 — 1-3 초 청크 단위 처리만
- 11. Real-time first-token latency 100-300ms — sub-100ms 는 어려움

12. 한국어 fine-tuning 모델 부재 — multilingual base 사용
13. Background noise 약점 — 작업장 소음 시 WER 증가 (VAD 로 일부 보완)
14. Punctuation 복원 약함 — 한국어 띄어쓰기 incomplete
15. RPi5 medium 0.5x realtime — 실시간 부족, small 까지가 한계

6. 대안 비교

항목	faster-whisper	OpenAI Whisper (원본)	OpenAI API (G6)	Vosk
속도	4-5x	1x baseline	cloud 변동	real-time stream
라이선스	MIT	MIT	API 비용	Apache 2.0
한국어 정확도	✓90-93% (m)	✓90-93%	✓95%+	75-85%
오프라인	✓	✓	✗	✓
FALCON-1	✓MUST	비권장 (느림)	비채택	비권장 (정확도)

7. FALCON-1 적용 결정

결정 항목	값
채택 여부	MUST 채택
도입 시점	Sprint 3 (음성 명령 통합)
primary 처리 위치	TUF Dash F15 (RTX 3060) — medium FP16
fallback (GPU 부하 시)	RPi5 ARM CPU — small INT8
트리거	ESP32 헬멧 PTT primary, Silero VAD(G2) fallback
언어	한국어 (ko)
Beam size	5 (정확도 우선)

결정 항목	값
VAD filter	True (내장 Silero)
목표 정확도	WER $\leq$ 10% (한국어 명령)
주요 의존성	A4 micro-ROS (헬멧), G2 Silero VAD, B2 PTP

8. 참고

- GitHub : <https://github.com/SYSTRAN/faster-whisper>
- CTranslate2 : <https://github.com/OpenNMT/CTranslate2>
- OpenAI Whisper 논문 : Radford et al. 2022
- ROS 2 wrapper : 다수 (whisper_ros, faster_whisper_ros 등)
- Whisper 한국어 정확도 : <https://github.com/openai/whisper#available-models-and-languages>

G2. Silero VAD

BLUF ★★★★★ MUST 채택. Voice Activity Detection의 ROS 2 표준 — 음성 vs 비음성 자동 구분으로 ASR 트리거. v1.0 PTT primary 정책에서는 fallback 역할이나 v1.1+ hands-free 운용 시 핵심. RPi5 ARM CPU에서 5% 부하, 5MB 경량 모델. 다국어 language-agnostic.

1. 개요

항목	내용
풀네임	Silero Voice Activity Detector
라이선스	MIT
관리	Silero AI (러시아 NLP·음성 회사)

항목	내용
모델 크기	5 MB (PyTorch JIT)
언어 지원	language-agnostic (모든 언어 동일 성능)
속도	RPi5 ARM 5% CPU, x86 1% CPU
입력	16 kHz mono PCM, 30ms 청크
출력	speech probability (0-1)
faster-whisper 통합	vad_filter=True 내장

2. 적용 방법

```
# Python 설치
pip install silero-vad

# 또는 faster-whisper 내장 사용 (G1)
segments, info = model.transcribe(
    audio, language='ko',
    vad_filter=True,
    vad_parameters=dict(
        min_silence_duration_ms=500,
        threshold=0.5,
    ),
)

# 독립 사용 (PTT-less hands-free)
from silero_vad import load_silero_vad, get_speech_timestamps
model = load_silero_vad()
speech_timestamps = get_speech_timestamps(
    audio_chunk, model, sampling_rate=16000)
if speech_timestamps:
    # 음성 감지 → ASR 트리거
    pass
```

3. 하드웨어 필요·제약

항목	요구	FALCON-1 적합성
CPU	ARM A53 또는 x86 dual	✔ RPi5, L1 모두
GPU	불필요	✔

항목	요구	FALCON-1 적합성
RAM	100 MB	✓
입력	16 kHz mono float32	✓ESP32 헬멧 표준
latency	30ms 청크 단위	✓real-time

4. 장점·단점 요약

장점 :

- language-agnostic — 한국어·영어·일본어 모두 동일 성능
- RPi5 5% CPU 매우 가벼움
- MIT 라이선스 상용 친화
- faster-whisper 내장 통합 — 별도 작업 거의 없음
- Real-time 30ms 청크 — sub-100ms latency

단점 :

- 배경 소음 false positive — 작업장 망치질·드릴 소리 시 음성으로 오인
- Threshold tuning 필요 — 0.3 (민감) vs 0.7 (보수) 작업 환경별
- Speaker identification 불가 — 누가 말했는지 구분 안 함
- v1.0 PTT primary 면 사실상 fallback 역할

5. FALCON-1 적용 결정

결정 항목	값
채택 여부	MUST 채택 (faster-whisper 내장)
도입 시점	Sprint 3 (G1과 동시)
사용 모드	v1.0 = PTT fallback / v1.1+ = hands-free primary

결정 항목	값
Threshold	0.5 (default), 작업장 소음 측정 후 조정
min_silence	500 ms (한국어 자연스러운 휴지)
주요 의존성	G1 faster-whisper, A4 micro-ROS

6. 참고

- GitHub : <https://github.com/snakers4/silero-vad>
- Silero AI : <https://www.silero.ai/>

G3. Piper TTS (한국어)

BLUF ★★★★★ MUST 채택. 빠르고 가벼운 ONNX 기반 TTS, RPi5 ARM CPU에서 실시간 한국어 음성 생성 (~200ms latency). MIT 라이선스, 한국어 ko-KR ONNX 모델 공식 제공. v1.0 음성 응답 ('공구 분류 시작합니다', '드라이버 가져왔습니다' 등) 표준.

1. 개요

항목	내용
풀네임	Piper TTS
라이선스	MIT
관리	Rhasspy + Mike Hansen
기반	VITS 모델 + ONNX runtime
언어	30+ 언어 (ko-KR 포함)
모델 크기	20-100 MB (언어·voice 별)

항목	내용
속도	RPi5 ARM 0.3-1x realtime, x86 5-10x realtime
latency (first audio)	~200 ms
출력	16 kHz / 22 kHz mono WAV

2. 적용 방법

2.1 설치

```
# Piper 바이너리 다운로드 (GitHub release)
wget https://github.com/rhasspy/piper/releases/download/v1.2.0/piper_linux_x86_64.tar.gz
tar -xzf piper_linux_x86_64.tar.gz

# 한국어 voice 모델 다운로드
# https://huggingface.co/rhasspy/piper-voices/tree/main/ko
wget https://huggingface.co/rhasspy/piper-voices/resolve/main/ko/ko_KR/ glow_kss/medium/ko_KR-
glow_kss-medium.onnx
wget https://huggingface.co/rhasspy/piper-voices/resolve/main/ko/ko_KR/ glow_kss/medium/ko_KR-
glow_kss-medium.onnx.json

# Python wrapper
pip install piper-tts
```

2.2 ROS 2 통합

```
# piper_tts_node.py
import rclpy
from rclpy.node import Node
from std_msgs.msg import String
from audio_common_msgs.msg import AudioData
import subprocess
import wave
import io

class PiperNode(Node):
    def __init__(self):
        super().__init__('piper_tts')
        self.voice = '/home/lgh/falcon1/voices/ko_KR-glow_kss-medium.onnx'
        self.sub = self.create_subscription(
            String, '/tts/text', self.cb, 10)
        self.pub = self.create_publisher(
            AudioData, '/helmet/audio_out', 10)

    def cb(self, msg):
        # Piper CLI 호출 (또는 Python API)
        result = subprocess.run(
```

```
['piper', '--model', self.voice, '--output_raw'],
input=msg.data.encode(),
capture_output=True)
# raw PCM 16-bit 22kHz
audio = AudioData()
audio.data = list(result.stdout)
self.pub.publish(audio)
self.get_logger().info(f'[TTS] {msg.data}')
```

2.3 한국어 voice 옵션

voice	품질	속도	추천
ko_KR-glow_kss-low	기본	0.5x realtime	RPi5 권장
ko_KR-glow_kss-medium	자연스러움	0.3x realtime	✔FALCON-1 권장
ko_KR-glow_kss-x_low	기계적	1x realtime	비권장

3. 하드웨어 필요·제약

항목	요구	FALCON-1 적합성
CPU	ARM A53 또는 x86	✔RPi5 ARM
GPU	불필요	✔
RAM	200 MB (모델 로드)	✔
속도 RPi5	0.3-0.5x realtime	□ 짧은 응답 (5-15초)에 200-500ms latency
속도 x86	5-10x realtime	✔L1 즉시
디스크	50 MB (medium voice)	✔

4. 장점

- 16. RPi5 ARM CPU 실시간 — GPU 불필요
- 17. MIT 라이선스 상용 친화
- 18. 한국어 ko-KR voice 공식 제공 (ko_KR-glow_kss)

- 19. ~200ms first audio latency — 자연스러운 응답
- 20. ONNX runtime — 다양한 platform (Linux, macOS, Windows, Android)
- 21. CLI + Python API 모두 지원
- 22. 다국어 30+ — 일본어 추가도 즉시 가능

5. 단점·한계

- 23. 기계적 톤 — Coqui XTTS v2 (G5) 같은 자연스러움 부족
- 24. Voice cloning 불가 — 사용자 음성 학습 안 됨
- 25. Emotion 제어 약함 — neutral 톤 한정
- 26. RPi5 0.3x realtime — 긴 응답 (30 초+) 시 지연 누적
- 27. Sub-200ms 는 어려움 — sub-100ms 는 별도 streaming TTS 필요

6. 대안 비교

항목	Piper	Coqui XTTS v2 (G5)	Google TTS API	Festival/eSpeak
라이선스	MIT	MPL 2.0	API 비용	GPL
RPi5 실시간	✓	✗	—	✓
한국어	✓ko-KR	✓다국어	✓	약함
자연스러움	기본	✓✓	✓✓	기계적
오프라인	✓	✓	✗	✓
FALCON-1	✓ MUST primary	Sprint 5 narrative	비채택	비권장

7. FALCON-1 적용 결정

결정 항목	값
채택 여부	MUST 채택
도입 시점	Sprint 3 (G1·G2와 동시)
처리 위치	RPi5 (CPU만으로 충분)
Voice 모델	ko_KR-glow_kss-medium
출력	16 kHz mono WAV → ESP32 헬멧 audio_out
응답 길이	5-15초 권장 (긴 응답 chunk 분리)
v1.1 검토	Coqui XTTS v2 (자연스러움)
주요 의존성	A4 micro-ROS, ROS 2 audio_common_msgs

8. 참고

- GitHub : <https://github.com/rhasspy/piper>
- Voice 다운로드 : <https://huggingface.co/rhasspy/piper-voices>
- Rhasspy 프로젝트 : <https://rhasspy.readthedocs.io/>

G4. Whisper-large v3 turbo (2024-10)

BLUF ★★★★★ SHOULD (BRAVO 한정, Sprint 4 검토). 2024-10 OpenAI 공개 large-v3 turbo 는 large-v3 대비 3x 빠르고 동등 정확도 (한국어 95%+). RTX 3060 6GB는 marginal, BRAVO 17 D7V (RTX 4060+ 8GB)에서 3x realtime. ASR 정확도 95% 사수 결정 시 채택, v1.0 medium에서 정확도 부족 시 fallback.

1. 개요

항목	내용
풀네임	Whisper large-v3 turbo
출시	2024년 10월
라이선스	MIT (OpenAI 공개)
파라미터	809M (large-v3 1.55B의 절반)
속도	large-v3 대비 3x
VRAM (FP16)	약 3.2 GB
VRAM (INT8)	약 1.8 GB
한국어 WER	5-8% (large-v3와 동등)
faster-whisper 통합	model='large-v3-turbo' 지정

2. 적용 방법

```
# faster-whisper에서 직접 사용
from faster_whisper import WhisperModel

# BRAVO 17 D7V (RTX 4060+ 8GB) FP16
model = WhisperModel('large-v3-turbo', device='cuda', compute_type='float16')

# 또는 INT8 (VRAM 절감)
model = WhisperModel('large-v3-turbo', device='cuda', compute_type='int8_float16')

# 사용은 G1과 동일
segments, _ = model.transcribe(audio, language='ko', beam_size=5)
```

3. medium vs large-v3 turbo 비교 (FALCON-1)

항목	medium (G1 default)	large-v3 turbo (G4)
파라미터	769 M	809 M (비슷)
VRAM FP16	2.5 GB	3.2 GB

항목	medium (G1 default)	large-v3 turbo (G4)
RTX 3060 속도	4x realtime	2x realtime (marginal)
RTX 4060 속도	8x realtime	3x realtime
한국어 WER	7-10%	5-8% (+2%)
FALCON-1 v1.0	✔TUF primary	BRAVO Sprint 4

4. FALCON-1 적용 결정

결정 항목	값
채택	SHOULD (BRAVO 한정, Sprint 4)
조건	ASR 정확도 95%+ 사수 결정 시
처리 위치	BRAVO 17 D7V (RTX 4060+ 8GB)
VRAM 동시 운용	YOLOv11-m + Whisper-turbo = $\sim 5 + 3.2 = 8.2$ GB (한계선)
v1.0 사용 여부	medium으로 시작 → 정확도 부족 시 turbo 전환
주요 의존성	G1 faster-whisper (동일 라이브러리)

5. 참고

- OpenAI 공개 : <https://github.com/openai/whisper/discussions/2363>
- faster-whisper 통합 : <https://github.com/SYSTRAN/faster-whisper#large-v3-turbo>

G5. Coqui XTTS v2

BLUF ★★★ SHOULD (Sprint 5 narrative). 자연스러운 다국어 TTS, voice cloning 6초 sample 로 가능. 한국어 + 16개 언어 동시 지원. v1.0 PoC는 Piper(G3)로 충분, XTTS v2는 Sprint 5

narrative 강화 — 시연 음성 품질 격상. RTX 3060에서 1-2x realtime.

1. 개요

항목	내용
풀네임	Coqui XTTS v2
라이선스	Coqui Public Model License (비상업 무료, 상용 별도)
관리	Coqui (회사 폐업 후 커뮤니티)
파라미터	1.8 B
VRAM	약 4 GB FP16
언어	16 (한국어 포함)
voice cloning	6초 sample로 가능
속도 RTX 3060	1-2x realtime

2. FALCON-1 사용 시나리오 (Sprint 5)

- 발표 시연 음성 품질 격상 — Piper 의 기계적 톤 → 자연스러운 한국어
- Voice cloning narrative — 사용자 본인 음성으로 6 초 학습 → 발표 시 자기 음성 재생
- Emotion control — happy / serious / calm 톤 제어
- v1.1 다국어 확장 — 일본어·영어 동시 지원 narrative

3. 하드웨어 필요·제약

항목	요구	FALCON-1 적합성
GPU	RTX 3060 6GB+	✔TUF, BRAVO 모두 가능
VRAM	4 GB FP16	▣ 다른 모델과 동시 운용 한계

항목	요구	FALCON-1 적합성
RAM	8 GB	✓
속도	1-2x realtime (RTX 3060)	□ 짧은 응답에는 OK, 긴 응답 지연
latency	~500ms first audio	□ Piper 대비 2x 지연

4. 장점·단점

장점 :

- 자연스러움 — Piper 대비 voice quality 격상
- Voice cloning — 사용자 본인 목소리
- 16 언어 동시 — 다국어 narrative
- Emotion 제어

단점 :

- Coqui 회사 폐업 (2024) — 커뮤니티 유지
- CPM 라이선스 — 상용 별도 협의
- VRAM 4GB 점유 — 다른 모델과 경합
- 500ms latency — Piper 대비 2x 느림

5. FALCON-1 적용 결정

결정 항목	값
v1.0 채택	비채택 (Piper로 충분)
Sprint 5 검토	발표 영상 품질 강화 narrative
처리 위치	TUF 또는 BRAVO (VRAM 여유 시)
Voice cloning narrative	사용자 6초 sample → 자기 음성

결정 항목	값
v1.1 본격	다국어 (일본어·영어) 지원

6. 참고

- GitHub : <https://github.com/coqui-ai/TTS>
- XTTS v2 모델 : <https://huggingface.co/coqui/XTTS-v2>
- 커뮤니티 fork : <https://github.com/idiap/coqui-ai-TTS>

G6. OpenAI Whisper API (cloud)

BLUF ★★ 비채택 (외부 의존). Cloud API로 한국어 95%+ 정확도, 그러나 FALCON-1 옵션 C+ 'edge-deployable' narrative 정면 위배 + 인터넷 의존 + API 비용. faster-whisper(G1)로 동일 정확도 오프라인 달성 가능.

1. 비채택 사유

28. 외부 의존 — 시연 시 인터넷 끊김 risk
29. narrative 위배 — 옵션 C+ 'onboard 추론' 자랑 불가
30. API 비용 — \$0.006 / 분 (시연 30 분 = \$0.18, 누적 부담)
31. Latency 변동 — cloud RTT 200-500ms 추가
32. 개인정보 — 음성이 OpenAI 서버 전송 (사내 정책 검토 부담)

2. FALCON-1 적용 결정

결정 항목	값
채택	비채택 (외부 의존, faster-whisper G1로 대체)

결정 항목	값
v2.0+ 검토	Production tethered 환경에서 99% 정확도 필요 시

3. 참고

- OpenAI API : <https://platform.openai.com/docs/guides/speech-to-text>

G7. WhisperX

BLUF ★★★ SHOULD (Sprint 4 검토). faster-whisper + word-level timestamp + speaker diarization. v1.0 단일 작업자 환경에서는 word timestamp가 일부 가치 (음성 명령 정확한 시작·종료 시각), v1.1+ 다중 작업자 시 speaker diarization 가치. RTX 3060 4x realtime, 추가 부담 적음.

1. 개요

항목	내용
풀네임	WhisperX (Whisper + Word-level Alignment + Diarization)
라이선스	BSD-2-Clause
관리	Max Bain (Oxford VGG)
기반	faster-whisper + wav2vec2 alignment + pyannote.audio diarization
속도	faster-whisper 대비 +20% overhead
VRAM	추가 1-2 GB (alignment 모델)

2. FALCON-1 사용 시나리오

- v1.0 — word timestamp 로 명령 시작·종료 정확 (handover timing critical 시 활용)

- v1.1 — 다중 작업자 시 'who said what' diarization
- 학습 데이터 라벨링 — burn-in 수집 음성 자동 라벨
- ROS 2 timestamp 정합 — PTP 동기화 결합으로 정확한 명령 시각

3. FALCON-1 적용 결정

결정 항목	값
v1.0 채택	SHOULD (Sprint 4 검토)
조건	word timestamp 가치 발견 시
v1.1 본격	다중 작업자 diarization
주요 의존성	G1 faster-whisper (동일 라이브러리)

4. 참고

- GitHub : <https://github.com/m-bain/whisperX>
- 논문 : Bain et al. INTERSPEECH 2023

G8. ESPnet (한국어 ASR/TTS)

BLUF ★★ 비채택 (학술용). End-to-end ASR/TTS toolkit, 학술 baseline 표준. Whisper + Piper 에 사실상 대체됨. 학술 paper 비교용으로 보존, FALCON-1 production 채택 안 함.

1. 개요 + 비채택 사유

항목	내용
풀네임	End-to-end Speech Processing Toolkit

항목	내용
라이선스	Apache 2.0
관리	ESPnet 커뮤니티 (학술)
기능	ASR + TTS + ST + SLU 통합
한국어 지원	✔KsponSpeech 등

2. 비채택 사유

- 33. Whisper(G1) + Piper(G3)로 production 충분
- 34. ESPnet 은 학습 toolkit — 사용자 자체 모델 학습 시 가치
- 35. ROS 2 통합 약함 — 자체 wrapper 필요
- 36. 학습 시간 부담 — KsponSpeech 학습 수일~수주
- 37. 학회 paper baseline 비교용으로만 가치

3. FALCON-1 적용 결정

결정 항목	값
채택	비채택 (Whisper로 충분)
학술용	v1.1+ 학회 paper baseline 비교 시

4. 참고


- GitHub : <https://github.com/espnet/espnet>
- KsponSpeech : <https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=123>


영역 G 종합 결론

1. 채택 / 비채택 정리

#	기술	v1.0 채택	도입 Sprint	역할
G1	faster-whisper medium	✔MUST	Sprint 3	한국어 ASR 90-93%
G2	Silero VAD	✔MUST	Sprint 3	음성 활성화 (faster-whisper 내장)
G3	Piper TTS	✔MUST	Sprint 3	한국어 응답 ~200ms
G4	Whisper-large v3 turbo	BRAVO SHOULD	Sprint 4	ASR 95%+ 사수
G5	Coqui XTTS v2	SHOULD (Sprint 5)	Sprint 5	발표 영상 품질 narrative
G6	OpenAI Whisper API	비채택	—	외부 의존
G7	WhisperX	SHOULD (Sprint 4)	Sprint 4	Word timestamp + diarization
G8	ESPnet	비채택 (학술)	—	학술 baseline

2. 통합 음성 Pipeline





3. v1.0 운용 정책

항목	v1.0 정책
트리거	PTT (Push-To-Talk) primary
VAD	fallback (PTT 미사용 시 또는 hands-free 시연)
ASR 모델	faster-whisper medium (TUF GPU)
ASR fallback	small INT8 (RPi5 CPU, GPU 부하 시)
TTS	Piper ko_KR-glow_kss-medium (RPi5 CPU)
언어	한국어 (ko)
End-to-end latency	PTT release → 응답 음성 < 1.5초
정확도	WER ≤ 10% (medium), ≤ 5% (turbo Sprint 4)

4. Sprint 별 도입 list

Sprint	도입 기술	주요 작업
Sprint 2	ESP32-S3 micro-ROS audio	헬멧 펌웨어 — 마이크 16kHz stream + PTT + LED

Sprint	도입 기술	주요 작업
Sprint 3	G1 faster-whisper + G2 VAD + G3 Piper	음성 명령 → 텍스트 → 응답 통합 pipeline
Sprint 4	G4 Whisper-large turbo (선택) + G7 WhisperX (선택)	정확도 95% 사수 시도, word timestamp
Sprint 5	G5 Coqui XTTS v2 (선택)	발표 영상 음성 품질 격상

5. 잔여 위험 및 대응

#	위험	심각도	대응
1	ESP32 Wi-Fi 끊김 시 음성 stream 손실	□ Med	Serial fallback 펌웨어, 16kHz buffer 1초 유지
2	작업장 소음 시 VAD false positive	□ Med	PTT primary 운용, threshold 0.7 보수
3	한국어 WER 10% 미달 시 명령 인식 실패	□ Med	Sprint 4 turbo 전환, 명령 어휘 제한 (Function calling)
4	RTX 3060 VRAM 한계 (Whisper + YOLO + MediaPipe)	□ Low	동시 운용 우선순위, 동적 load/unload
5	Piper 한국어 voice 불자연스러움	□ Low	Sprint 5 Coqui XTTS 시도
6	PTT 버튼 디바운싱·반응성	□ Low	ESP32 펌웨어 50ms debounce

6. 검증 시험 (Test Plan 매핑)

Test ID	내용	Sprint	성공 기준
T-HRI-01	한국어 명령 WER (medium)	Sprint 3	≤ 10% (KsponSpeech 일부)
T-HRI-02	End-to-end PTT → 응답 latency	Sprint 3	< 1.5초 (95%)

Test ID	내용	Sprint	성공 기준
T-HRI-03	VAD false positive (작업장 소음)	Sprint 4	< 5% / 시간
T-HRI-04	한국어 명령 WER (turbo, BRAVO)	Sprint 4	≤ 5%
T-HRI-05	Piper TTS 자연스러움 평가 (MOS)	Sprint 4	≥ 3.5 / 5
T-HRI-06	Wi-Fi 끊김 시 fallback 시간	Sprint 5	< 3초 복구

7. 다음 작성 영역

영역 G HRI·음성 8종 분석 완료. 후속 영역 :

- 38. 영역 H — Grasp Planning (6 종) : Hand-coded grasp, GG-CNN, Contact-GraspNet, GraspNet-1Billion, AnyGrasp, Graspl!
- 39. 영역 I — LLM · Reasoning (6 종)
- 40. 영역 J — Learning RL · Imitation · VLA (8 종)
- 41. 영역 K — Sim · CI · Logging (8 종)
- 42. 영역 L — Safety · Power (6 종)

부록 — 변경 이력

버전	일자	내용	작성
v0.1	2026-04-30	영역 G HRI·음성 8종 초안 (ORANGE accent)	이건희, CTO 페르소나