

FALCON-1 PoC

기술 분석 보고서 (Tech Analysis Report)

영역 J — Learning RL/Imitation/VLA (8종)

[accent : MAGENTA]

프로젝트 : FALCON-1 (Flow-Assisted Logistics & Collaborative Operation Network — One)

팀 : NERDLABS | 버전 : v0.1 | 작성일 : 2026-04-30

작성자 : 이건희 (NERDLABS 팀장) | 검토 : CTO 페르소나

보고서 BLUF

BLUF FALCON-1 Learning 영역 8종 분석 결과: v1.0 PoC는 Plan A (hand-coded MoveIt) primary, Plan B/C VLA Dual-Track 시도 결정. Behavior Cloning + ACT = SHOULD baseline (Sprint 4-5, 50회 demo 데이터), Diffusion Policy = v1.1, TinyVLA = v1.0 limited Scene B 가능 (Sprint 5 시간 여유 시), OpenVLA-OFT+ = v1.1 권장 (BRAVO 8GB INT4), $\pi_0/\pi_{0.5}$ = v1.1 narrative 핵심, GR00T N1.5 = v1.2+ humanoid narrative, OpenVLA 7B = RTX 5090 학습용. v1.0 demo 직접 가치는 Plan A 결정적 동작이 우월하나 v1.1+ 학습 narrative는 본 영역이 핵심.

본 보고서는 영역 D(MoveIt 2 + ros2_control) + E(YOLOv11 + MediaPipe) + F(D405 RGB-D) + I(LLM)을 전제로 한다. Plan A가 production primary, Plan B/C는 학회·발표 narrative 강화 + v1.1+ 진화 경로.

본 영역의 accent 색상은 MAGENTA (학습·진화 의미)을 사용한다.

영역 J — 8종 요약 매트릭스

#	기술	타입	데이터	VRAM (학습)	권장도	적용
J1	Behavior Cloning	Imitation baseline	50-200 demo	8 GB	★★★	SHOULD baseline
J2	ACT (Action Chunking Transformer)	Imitation transformer	50-100 demo	12 GB	★★★★	SHOULD (Sprint 5)
J3	Diffusion Policy	Diffusion-based imitation	100-500 demo	16 GB	★★★	v1.1
J4	OpenVLA 7B	VLA foundation	Pretrained + finetune	24+ GB	★★★	RTX 5090 학습
J5	OpenVLA-OFT+	OpenVLA fine-tune (INT4)	100-300 demo	16 GB	★★★★	v1.1 권장

#	기술	타입	데이터	VRAM (학습)	권장도	적용
J6	$\pi 0$ / $\pi 0.5$	Physical Intelligence VLA	Pretrained large	24+ GB	★★★★	v1.1 narrative 핵심
J7	TinyVLA	1.4B 경량 VLA	50-100 demo	6 GB	★★★	v1.0 Scene B 가능
J8	GR00T N1.5	NVIDIA humanoid VLA	대규모 pretrained	32+ GB	★★	v1.2+ humanoid

J1. Behavior Cloning (BC)

BLUF ★★★ SHOULD baseline. Imitation learning 가장 단순 형태 — observation → action 직접 매핑 (supervised learning). 50-200 demo로 80-85% task 성공률 가능. v1.0 Plan B 학습 시작점, MLP 또는 ResNet 백본으로 RTX 3060에서 1-2시간 학습. 학회 paper baseline 표준.

1. 개요

항목	내용
풀네임	Behavior Cloning
방식	Observation (RGB + state) → Action 직접 매핑
손실함수	MSE 또는 negative log-likelihood
데이터	50-200 expert demonstration
성공률	80-85% (단순 task)
학습 시간	1-2h (RTX 5090)

항목	내용
VRAM (학습)	8 GB
라이선스	오픈소스 구현 다수 (BSD/MIT)

2. FALCON-1 적용 시나리오

- Sprint 4-5 데이터 수집 — MoveIt Servo (D6) + joystick teleop 으로 50 회 pick-and-place 시연
- BC 모델 학습 (RTX 5090) → BRAVO 8GB 로 export
- Plan B 비교 — Plan A 결정적 동작 vs BC 학습 동작 학회 narrative
- Sprint 5 burn-in 일부 시도 — BC 100 회 성공률 측정

3. 하드웨어 필요·제약

항목	요구	FALCON-1 적합성
GPU 학습	RTX 3060 6GB 이상	✔ RTX 5090 24GB
GPU 추론	RTX 3060 6GB	✔ TUF, BRAVO
VRAM 학습	8 GB (ResNet 백본)	✔
VRAM 추론	2-3 GB	✔
데이터	50-200 demo, 각 30-60초	□ Sprint 4-5 ~10시간 수집
속도	50-100 FPS 추론	✔

4. 장점·단점 요약

장점 :

- 학습 빠름 — 1-2h

- 데이터 적음 — 50 회로 시작 가능
- 학회 paper baseline 표준
- VRAM 부담 작음

단점 :

- Distribution shift 약점 — demo 외 상황에서 실패율 ↑
- Compounding error — 시퀀스 길어질수록 누적 오차
- 성공률 80-85% — Plan A 95% 미달

5. FALCON-1 적용 결정

결정 항목	값
채택	SHOULD baseline (Sprint 4-5)
학습 위치	RTX 5090 학습 워크스테이션
추론 위치	BRAVO 또는 TUF
데이터 수집	Movelt Servo + joystick teleop, 50회
v1.0 production 채택	비채택 (Plan A 우월)
학회 paper 가치	baseline 비교용 강력

6. 참고

- 논문 : Pomerleau 1989 (ALVINN, NIPS), Bain & Sammut 1995
- Mobile ALOHA : <https://mobile-aloha.github.io/>
- LeRobot : <https://github.com/huggingface/lerobot>

J2. ACT (Action Chunking Transformer)

BLUF ★★★★★ SHOULD (Sprint 5 narrative 핵심). Tony Zhao et al. 2023, Mobile ALOHA의 핵심 방법. observation → 100 step action chunk를 한 번에 예측하는 transformer + CVAE. 50 회 demo로 90%+ 성공률, BC 대비 우월. RTX 3060 8GB 학습 가능, BRAVO 8GB 추론 가능. v1.0 Plan B/C 학습 narrative의 핵심 후보.

1. 개요

항목	내용
풀네임	Action Chunking with Transformers
출시	2023년 (RSS 2023, Mobile ALOHA)
라이선스	MIT
관리	Tony Zhao + Stanford + Google DeepMind
방식	Transformer + CVAE, action chunk 100 step 예측
입력	RGB images (multi-view) + joint state
출력	100 step action chunk
성공률	90%+ (50회 demo, 단순 task)
학습 시간	5-8h (RTX 5090)
VRAM 학습	12 GB
VRAM 추론	3-4 GB

2. 적용 방법

2.1 데이터 수집 (Sprint 4-5)

Mobile ALOHA 패턴 – bimanual teleop
v1.0 FALCON-1 적용 시 단일 팔 또는 양팔 모두 가능

```
# Joystick teleop으로 50회 pick-and-place 시연
# - 각 시연 30-60초
# - RGB (chest + wrist Right) 30 FPS
# - joint state 100 Hz
# - 동기화 → MCAP 로깅 (영역 K)

# 데이터 구조
# falcon1_act_data/
#   └─ episode_000.h5      # RGB + state + action
#   └─ episode_001.h5
#   └─ ...
#   └─ episode_049.h5

# h5 내부:
#   /observations/images/chest      (T, H, W, 3) uint8
#   /observations/images/wrist      (T, H, W, 3) uint8
#   /observations/qpos               (T, 7) joint position
#   /observations/qvel               (T, 7) joint velocity
#   /action                          (T, 7) target joint position
```

2.2 학습 (RTX 5090)

```
# act_train.py (간략)
from act.detr.models.detr_vae import DETRVAE
import torch

model = DETRVAE(
    backbone='resnet18',
    num_queries=100,          # action chunk 길이
    state_dim=7,              # joint count
    action_dim=7,
    hidden_dim=512,
    dropout=0.1,
    nheads=8,
    enc_layers=4,
    dec_layers=7,
)
model.cuda()

# 학습 5-8h on RTX 5090
# epochs=2000, batch=8, lr=1e-5
for epoch in range(2000):
    for batch in dataloader:
        a_hat, mu, logvar = model(batch.images, batch.qpos, batch.actions)
        loss = MSE(a_hat, batch.actions) + KL(mu, logvar)
        loss.backward()
        optimizer.step()
```

2.3 추론 (BRAVO 8GB)

```
# act_inference_node.py (ROS 2)
import rclpy
from rclpy.node import Node
```

```

from sensor_msgs.msg import Image, JointState
import torch

class ActInferenceNode(Node):
    def __init__(self):
        super().__init__('act_inference')
        self.model = torch.load('falcon1_act.pt')
        self.model.cuda().eval()

        self.action_buffer = []
        self.action_idx = 0

    def cb_step(self):
        # 100 step마다 새 chunk 예측
        if self.action_idx >= len(self.action_buffer):
            with torch.no_grad():
                actions = self.model.predict(
                    chest_img, wrist_img, qpos)
                self.action_buffer = actions # (100, 7)
                self.action_idx = 0

        # 다음 action 발행
        self.publish_action(self.action_buffer[self.action_idx])
        self.action_idx += 1

```

3. 하드웨어 필요·제약

항목	최소	권장	FALCON-1 적합성
GPU 학습	RTX 3060 8GB	RTX 4090+	✓ RTX 5090 24GB
GPU 추론	RTX 3060 6GB	RTX 4060+	✓ BRAVO
VRAM 학습	12 GB	—	✓ RTX 5090 24GB
VRAM 추론	3-4 GB	—	✓
데이터 수집 시간	10-20시간 (50회)	—	□ Sprint 4-5
학습 시간	5-8h	—	✓
추론 속도	20-30 FPS	—	✓ BRAVO 30+ FPS

4. 장점

- 1. Mobile ALOHA narrative — 학회 paper 에서 가장 인용되는 imitation 방법
- 2. Action chunking — compounding error 완화 (100 step 한 번에)
- 3. CVAE — multi-modal action distribution
- 4. 50 회 demo 로 90%+ 성공률
- 5. MIT 라이선스
- 6. Stanford LeRobot 통합 가능

5. 단점·한계

- 7. 학습 시간 5-8h — BC 대비 4x
- 8. VRAM 12GB 학습 부담
- 9. Hyperparameter tuning — chunk size · queries 수 등
- 10. Distribution shift 여전 약점
- 11. v1.0 직접 가치 제한 — Plan A 우월

6. FALCON-1 적용 결정

결정 항목	값
채택	SHOULD (Sprint 5 narrative 핵심)
학습 위치	RTX 5090 학습 워크스테이션
추론 위치	BRAVO 17 D7V
데이터	50회 (양팔 동시 또는 단일 팔)
v1.0 production	비채택 (Plan A primary)
학회 narrative	Mobile ALOHA 패턴 학습 비교 강력
주요 의존성	D6 MoveIt Servo (teleop), K7 MCAP (데이터 로깅)

7. 참고

- Mobile ALOHA 사이트 : <https://mobile-aloha.github.io/>
- 논문 : Zhao et al. RSS 2023 "Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware"
- GitHub : <https://github.com/tonyzhaozh/act>
- LeRobot 통합 : <https://github.com/huggingface/lerobot>

J3. Diffusion Policy

BLUF ★★★ v1.1 검토. Cheng Chi et al. 2023, diffusion model 기반 action prediction. 100-500회 demo 필요 + 학습 시간 길지만 multi-modal action 표현력 우월. v1.0 PoC에는 데이터 시간 부담, v1.1+ 본격 도입 시 narrative 핵심.

1. 개요

항목	내용
출시	2023년 (RSS 2023)
라이선스	MIT
관리	Cheng Chi (Columbia) + TRI
방식	Diffusion model (DDPM) action 생성
데이터	100-500 demo
학습 시간	12-24h (RTX 5090)
VRAM 학습	16 GB
성공률	92-95% (단순 task)

2. ACT vs Diffusion Policy 비교 (FALCON-1)

항목	ACT (J2)	Diffusion Policy (J3)
방식	Transformer + CVAE	Diffusion (DDPM)
데이터	50-100 demo	100-500 demo
학습 시간	5-8h	12-24h
성공률	90%	92-95%
multi-modal	CVAE	📈 우월
FALCON-1	v1.0 narrative	v1.1

3. FALCON-1 적용 결정

결정 항목	값
v1.0 채택	비채택 (시간·데이터 부담)
v1.1 검토	ACT 후 trajectory 품질 강화 narrative
데이터 수집 시간 ↑	100-500 demo = 30-60시간 수집

4. 참고

- 논문 : Chi et al. RSS 2023
- GitHub : https://github.com/columbia-ai-robotics/diffusion_policy

J4. OpenVLA 7B

BLUF ★★★ 학습 워크스테이션 한정. Stanford 2024-06 출시 7B parameter VLA (Vision-Language-Action) foundation model, RT-2 후속 오픈소스. 추론 24GB VRAM (FP16) 또는

14GB (INT4) 부담으로 BRAVO 8GB는 한계 — RTX 5090에서 학습·시연. v1.0 PoC에는 직접 가치 제한, v1.1 OpenVLA-OFT+ (J5) fine-tune 후 INT4로 BRAVO 가능.

1. 개요

항목	내용
풀네임	OpenVLA 7B
출시	2024년 6월
라이선스	MIT (모델 + 코드)
관리	Stanford + Google DeepMind
파라미터	7 B
기반	Llama 2 7B + DINOv2 + SigLIP vision
학습 데이터	Open X-Embodiment (970K episodes)
VRAM 추론 FP16	24 GB
VRAM 추론 INT4	14 GB
VRAM 학습	32 GB+ (LoRA), 80GB+ (full)

2. FALCON-1 적용 결정

결정 항목	값
v1.0 채택	비채택 (BRAVO 8GB 한계)
v1.1 검토	OpenVLA-OFT+ (J5)로 INT4 시도
RTX 5090 학습	LoRA fine-tune 가능 (24GB OK)
narrative	Open X-Embodiment 970K episodes 강력

3. 참고

- 공식 : <https://openvla.github.io/>
- GitHub : <https://github.com/openvla/openvla>
- Open X-Embodiment : <https://robotics-transformer-x.github.io/>

J5. OpenVLA-OFT+ (Optimal Fine-Tuning)

BLUF ★★★★★ v1.1 권장. OpenVLA 7B를 작업별 fine-tune 후 INT4 양자화 → BRAVO 8GB GPU에서 추론 가능. 100-300회 demo로 fine-tune, 90%+ 성공률 + VLA narrative 동시 확보. v1.1 핵심 후보.

1. 개요

항목	내용
출시	2024-2025 (OpenVLA fine-tuning 표준화)
라이선스	MIT (OpenVLA 동일)
방식	OpenVLA 7B + LoRA + INT4 양자화
데이터	100-300 demo (FALCON-1 task별)
VRAM 추론 INT4	6-8 GB
성공률 (fine-tune 후)	90%+ on task

2. FALCON-1 적용 결정

결정 항목	값
v1.1 채택	권장 (BRAVO 8GB INT4)

결정 항목	값
학습 위치	RTX 5090 (LoRA fine-tune 24GB)
추론 위치	BRAVO 17 D7V (INT4 6-8GB)
데이터	100-300 demo (Sprint 5 + v1.1 추가)
narrative	Edge VLA inference + open foundation 강력

3. 참고

- OpenVLA fine-tuning : <https://openvla.github.io/>
- LoRA : Hu et al. 2021
- INT4 양자화 : bitsandbytes, AWQ, GPTQ

J6. $\pi 0$ / $\pi 0.5$ (Physical Intelligence)

BLUF ★★★★★ v1.1 narrative 핵심. Physical Intelligence (Karol Hausman + Sergey Levine) 2024-10 공개 generalist robot policy, 'Robot Foundation Model' 개념. $\pi 0$ base + $\pi 0.5$ (2025) 후속. v1.0 PoC에는 직접 가치 제한, v1.1+ 'Robot Foundation Model on edge' narrative 가장 강력.

1. 개요

항목	내용
풀네임	$\pi 0$ (Pi-Zero), $\pi 0.5$ (Pi-Zero-FAST)
출시	$\pi 0$: 2024-10, $\pi 0.5$: 2025
라이선스	Apache 2.0 (오픈소스)
관리	Physical Intelligence (Karol Hausman + Sergey Levine)

항목	내용
기반	Flow matching + Vision-Language-Action
파라미터	3B (π_0), 1.5B ($\pi_{0.5}$ FAST)
학습 데이터	10K+ hours teleoperation
narrative	'Robot Foundation Model' 개념 정립

2. FALCON-1 적용 시나리오

- v1.1 narrative 핵심 — '한국 최초 $\pi_0/\pi_{0.5}$ onboard 시연' 가능성
- Fine-tune 50-100 demo 로 task adapt
- $\pi_{0.5}$ FAST 1.5B 는 INT4 시 BRAVO 8GB 가능 (~3 GB)
- 학회 paper — Physical Intelligence 인용 narrative

3. FALCON-1 적용 결정

결정 항목	값
v1.0 채택	비채택 (학습 데이터·시간 부담)
v1.1 narrative	$\pi_{0.5}$ FAST INT4 BRAVO 시연
v1.2+	π_0 3B 본격 fine-tune

4. 참고

- Physical Intelligence : <https://www.physicalintelligence.company/>
- π_0 논문 : Black et al. 2024
- $\pi_{0.5}$ (FAST) : 2025 release

J7. TinyVLA (1.4B)

BLUF ★★★ v1.0 Scene B 가능 (Sprint 5 시간 여유 시). Wen et al. 2024 출시 1.4B 경량 VLA, RTX 3060 6GB FP16 또는 BRAVO 8GB에서 운용 가능. 50회 demo fine-tune으로 단순 task 성공. v1.0 PoC narrative 강화 후보 — Plan B/C에서 단일 시연.

1. 개요

항목	내용
출시	2024년
라이선스	Apache 2.0
관리	Wen et al.
파라미터	1.4 B (가장 작은 VLA)
VRAM FP16	5-6 GB
VRAM INT4	2-3 GB
데이터 fine-tune	50회
학습 시간	3-5h (RTX 5090)

2. FALCON-1 사용 시나리오 (Sprint 5)

- v1.0 limited Scene B — 단일 task (예: hammer pick) 학습 시연
- Plan B/C narrative — 'edge-deployable VLA' 키워드
- BRAVO 8GB FP16 OK, TUF 6GB INT4 로도 가능
- Sprint 5 시간 여유 시 1 주일 시도 가치

3. FALCON-1 적용 결정

결정 항목	값
v1.0 채택	Sprint 5 시간 여유 시 시도
데이터	50회 demo (단일 task)
추론 위치	BRAVO FP16 또는 TUF INT4
narrative	Plan B/C 'edge VLA' 시연

4. 참고

- 논문 : Wen et al. 2024 "TinyVLA: Towards Fast, Data-Efficient VLA Models"

J8. GR00T N1.5 (NVIDIA, 2025)

BLUF ★★ v1.2+ humanoid narrative. NVIDIA 2025 공개 humanoid robot foundation model, 32GB+ VRAM 부담. FALCON-1 v1.0/v1.1은 dual-arm mobile (humanoid 아님)이라 직접 적용 어려움. v1.2+ humanoid 진화 narrative 시 검토.

1. 개요

항목	내용
풀네임	GR00T N1.5 (Generalist Robot 00 Technology)
출시	2025년
라이선스	NVIDIA Source Code License
관리	NVIDIA Research
대상	humanoid robot (전신)
VRAM	32 GB+

2. FALCON-1 적용 결정

결정 항목	값
v1.0/v1.1 채택	비채택 (humanoid 아님 + VRAM 부담)
v1.2+ 검토	humanoid 진화 narrative 시

3. 참고

- NVIDIA GR00T : <https://developer.nvidia.com/isaac/gr00t>

영역 J 종합 결론

1. 채택 / 비채택 정리

#	기술	v1.0 채택	v1.1 채택	역할
J1	Behavior Cloning	SHOULD baseline	—	학회 paper baseline
J2	ACT	SHOULD (Sprint 5)	v1.0과 동일	Mobile ALOHA narrative 핵심
J3	Diffusion Policy	비채택	검토	데이터 100-500 부담
J4	OpenVLA 7B	비채택 (학습만)	OpenVLA-OFT+	RTX 5090 학습 워크스테이션
J5	OpenVLA-OFT+	비채택	권장 (INT4 BRAVO)	Edge VLA narrative
J6	$\pi 0$ / $\pi 0.5$	비채택	narrative 핵심	Robot Foundation Model
J7	TinyVLA	Scene B 시도	—	v1.0 limited 시연

#	기술	v1.0 채택	v1.1 채택	역할
		(Sprint 5)		
J8	GR00T N1.5	비채택	비채택	v1.2+ humanoid narrative

2. v1.0 vs v1.1 학습 narrative 진화 경로

[v1.0 PoC – 2026-06-04 시연] Plan A (primary) : Hand-coded MoveIt + Pilz LIN 성공률 95%+ 결정적 동작 ↑↑↑ demo 안정성 사수 └ Plan B/C (선택, 시간 여유 시): └─ J1 BC baseline (50회 demo) └─ J2 ACT (Sprint 5 narrative 핵심) └─ J7 TinyVLA Scene B 단일 시연 (선택) narrative: 'edge VLA + imitation'
[v1.1 – 2026 Q4 진화] Plan A (production primary) – 안정 보존 Plan B (학습 본격): └─ J2 ACT 50회 demo → 양팔 통합 └─ J3 Diffusion Policy 100-500 demo (선택) └─ J5 OpenVLA-OFT+ INT4 (BRAVO) ← 핵심 narrative: 'Open VLA on edge' 강력 Plan C (foundation model): └─ J6 π0.5 FAST 시도 ← 학회 paper 핵심 narrative: 'Robot Foundation Model'
[v1.2+ – 2027 production] multi-agent fleet + humanoid 진화 검토 └ J8 GR00T N1.5 (humanoid 결정 시)

3. v1.0 Sprint 4-5 데이터 수집 계획

Sprint	데이터 수집	시간	용도
Sprint 4	Movelt Servo + joystick teleop 셋업	5h	BC/ACT 데이터 수집 인프라
Sprint 5 week 1	BC 학습용 50회 demo	10h	J1 BC baseline
Sprint 5 week	ACT 학습 (RTX 5090, 5-8h)	8h	J2 ACT narrative

Sprint	데이터 수집	시간	용도
2			
Sprint 5 week 3	(선택) TinyVLA fine-tune	5h	J7 Scene B 시연
Sprint 5 week 4	burn-in + 비교 시험	10h	Plan A vs Plan B/C 정량 비교

4. 학회 paper narrative 구조 (제안)

- Title : 'FALCON-1: A Dual-Arm Mobile Manipulator with Hybrid Hand-Coded and Imitation Learning Approaches for Industrial Pick-and-Place'
- Section 1 : Plan A baseline (Hand-coded Movelt + Pilz LIN, 95% 성공률)
- Section 2 : Plan B comparison (BC, ACT, 50-100 회 demo)
- Section 3 : Plan C VLA exploration (TinyVLA, OpenVLA-OFT+) - v1.1 진화 경로
- Section 4 : 결과 — Plan A 95% vs Plan B 90% vs Plan C 85% (예상)
- Section 5 : Discussion — '안정성 vs 일반성 trade-off'

5. Sprint 별 도입 list

Sprint	도입 기술	주요 작업
Sprint 4	Movelt Servo + joystick teleop 셋업	데이터 수집 인프라
Sprint 5	J1 BC + J2 ACT (선택 J7 TinyVLA)	50회 demo + 학습 + 추론 + 비교 시험
v1.1	J5 OpenVLA-OFT+ + J6 π 0.5	narrative 강화

6. 잔여 위험 및 대응

#	위험	심각도	대응
1	Sprint 5 시간 부족 시 Plan B/C 미완	□ Med-High	Plan A primary 보존, Plan B BC만 baseline
2	데이터 수집 50회 시간 ~10시간	□ Med	Movelt Servo + joystick 셋업 사전 검증
3	ACT 학습 RTX 5090 한 번에 5-8h	□ Low	주말 학습 batch 운용
4	BRAVO VRAM 한계 (Whisper + YOLO + VLA)	□ Med	VLA 단독 모드 시연, 동시 운용 모델 줄임
5	Distribution shift — demo 외 상황 실패	□ Med	데이터 다양화 (다양한 box 위치 + 조명)
6	학회 paper 시기 — v1.0 PoC 결과로 paper 작성 부담	□ Low	v1.1까지 데이터 수집 후 paper 작성

7. 검증 시험 (Test Plan 매핑)

Test ID	내용	Sprint	성공 기준
T-LEARN-01	BC 50회 학습 후 성공률	Sprint 5	≥ 80% (단일 task)
T-LEARN-02	ACT 50회 학습 후 성공률	Sprint 5	≥ 90%
T-LEARN-03	Plan A vs Plan B 정량 비교	Sprint 5	Plan A ≥ Plan B (95% vs 90%)
T-LEARN-04	TinyVLA fine-tune (선택)	Sprint 5	단일 task 시연 성공
T-LEARN-05	데이터 수집 시간	Sprint 4-5	50회 demo < 15시간

8. 다음 작성 영역

영역 J Learning RL/Imitation/VLA 8종 분석 완료. 후속 영역 :

- 12. 영역 K — Sim · CI · Logging (8 종) : Isaac Sim 4.5, Isaac Lab, Genesis, Gazebo
Harmonic, MuJoCo 3.x, Foxglove Studio, MCAP 로깅, Grafana+Prometheus+Loki
- 13. 영역 L — Safety · Power (6 종) : Sub-1GHz E-stop, BMS, APC UPS, Safety PLC,
TÜV/SÜD, KTL/KTR/FITI

부록 — 변경 이력

버전	일자	내용	작성
v0.1	2026-04-30	영역 J Learning RL/Imitation/VLA 8종 초안 (MAGENTA accent)	이건희, CTO 페 르소나